

Tipologia i cicle de vida de les dades

Pràctica 2

Uoc

Com realitzar la neteja i anàlisi de les dades?

25% nota final

Data de lliurament

28 de maig de 2026

Pràctica 2 (25% nota final)

Presentació

En aquesta pràctica s'elabora un cas pràctic orientat a aprendre a identificar les dades rellevants per un projecte analític i usar les eines d'integració, neteja, validació i anàlisi de les mateixes. Per fer aquesta pràctica haureu de treballar en **grups de 2 persones**.

El lliurament d'aquesta pràctica s'ha de realitzar tal com s'especifica a l'apartat [Format i data de lliurament](#). Haureu de lliurar una memòria PDF amb les respostes als apartats, un repositori amb el codi font i un vídeo explicatiu, en el que ambdós integrants del grup han de comentar els aspectes més rellevants del projecte.

És important tenir en compte les següents consideracions a l'hora de lliurar la pràctica:

- És obligatori i **queda com a responsabilitat de cada estudiant revisar que l'arxiu lliurat és el correcte**. Un arxiu buit o no pertinent es considerarà com no lliurat.
- Perquè el lliurament es consideri com realitzat, s'ha de completar almenys el 25% de tota l'activitat.
- No podrà modificar-se cap element de la pràctica passada la data de lliurament (repositori, arxius de Google Drive, etc.).
- Així mateix, també és responsabilitat de l'estudiant assegurar-se que, en el moment del lliurament de la pràctica, **s'ha donat accés al professor als diferents elements privats que es lliurin** (p. ex., repositori GitHub privat o arxius restringits de Google Drive). El professor indicarà als Anuncis de l'aula el seu nom d'usuari en aquestes plataformes.
- No es poden fer grups amb alumnes de diferents aules.

Competències

En aquesta pràctica es desenvolupen les següents competències del Màster de Data Science:

- Capacitat d'analitzar un problema en el nivell d'abstracció adequat a cada situació i aplicar les habilitats i coneixements adquirits per abordar-lo i resoldre'l.
- Capacitat per aplicar les tècniques específiques de tractament de dades (integració, transformació, neteja i validació) per al seu posterior anàlisi.

Objectius

Els objectius concrets d'aquesta pràctica són:

- Aprendre a aplicar els coneixements adquirits i la seva capacitat de resolució de problemes en entorns nous o poc coneguts dintre de contextos més amplis o multidisciplinaris.
- Saber identificar les dades rellevants i els tractaments necessaris (integració, neteja i validació) per dur a terme un projecte analític.
- Aprendre a analitzar les dades adequadament per abordar la informació continguda en les dades.
- Identificar la millor representació dels resultats per tal d'aportar conclusions sobre el problema plantejat en el procés analític.
- Actuar amb els principis ètics i legals relacionats amb la manipulació de dades en funció de l'àmbit d'aplicació.
- Desenvolupar les habilitats d'aprenentatge que els permetin continuar estudiant d'una manera que haurà de ser en gran manera autodirigida o autònoma.
- Desenvolupar la capacitat de cerca, gestió i ús d'informació i recursos en l'àmbit de la ciència de dades.

Descripció de la Pràctica a realitzar

L'objectiu d'aquesta activitat serà el tractament del dataset creat a la Pràctica 1.

Important: el dataset cal que compti amb una àmplia varietat de dades numèriques i categòriques, entre les quals es trobi almenys una variable objectiu, així com comptar amb dades mancants i/o errònies, per a poder realitzar una anàlisi més rica i poder respondre a les diferents preguntes plantejades a l'enunciat de la pràctica. De no ser així, s'haurà de buscar la manera d'integrar més dades que compleixin amb aquests requisits a l'etapa d'integració (apartat 2).

Seguint les principals etapes d'un projecte analític, les diferents tasques a realitzar (i justificar) són les següents:

1. **Descripció del dataset.** Perquè és important i quina pregunta/problema pretén respondre? Resumeix breument les variables que el formen i el seu tamany.
2. **Integració i selecció** de les dades d'interès a analitzar. Pot ser el resultat adicionar diferents datasets o una subselecció útil de les dades originals, en base a l'objectiu que es vulgui aconseguir. Si es decideix treballar amb una selecció de les dades, és molt important que aquesta estigui degudament justificada. A més, es recomana mostrar un resum de les dades que permeti veure a simple vista les diferents variables i els seus rangs de valors.
3. **Neteja de les dades.**

- 3.1. Les dades contenen zeros, elements buits o altres valors numèrics que indiquin la pèrdua de dades? Gestiona cadascun d'aquests casos utilitzant el mètode d'imputació que consideris més adequat.
- 3.2. Identifica i gestiona adequadament el tipus de dada de cada atribut (p. ex. conversió de variables categòriques en `factor`).
- 3.3. Identifica i gestiona els valors extrems.
- 3.4. Justifica la necessitat d'altres mètodes de neteja per a aquest dataset en particular i, de ser necessari, aplica'ls.

4. Anàlisi de les dades.

- 4.1. Aplica un model supervisat i un no supervisat a les dades i comenta els resultats obtinguts.
- 4.2. Aplica una prova per contrast d'hipòtesi. Tingues en compte que algunes d'aquestes proves requereixen verificar prèviament la normalitat i homocedasticitat de les dades.

5. Representació dels resultats a partir de taules i gràfiques. Aquest apartat es pot respondre al llarg de la pràctica, sense la necessitat de concentrar totes les representacions en aquest apartat.

S'ha de representar tant el contingut del dataset per a observar les proporcions i distribucions de les diferents variables una vegada aplicada l'etapa de neteja, com els resultats obtinguts després de l'etapa d'anàlisi.

6. Resolució del problema. A partir dels resultats obtinguts, quines són les conclusions? Els resultats permeten respondre al problema?

7. Codi. Cal adjuntar el codi, preferiblement en R, amb el que s'ha realitzat la neteja, anàlisi i representació de les dades. Si ho preferiu, també podeu treballar en Python.

8. Vídeo. Realitzar un breu vídeo explicatiu de la pràctica (**màxim 10 minuts**) on tots els integrants de l'equip expliquin amb les seves pròpies paraules el desenvolupament de la pràctica, basant-se en les preguntes de l'enunciat per a justificar i explicar el codi desenvolupat. Aquest vídeo s'haurà de lliurar a través d'un enllaç al Google Drive de la UOC (<https://drive.google.com/>...), juntament amb l'enllaç al repositori Git lliurat.

Recursos

Els següents recursos són d'utilitat per la realització de la pràctica:

- Calvo M., Subirats L., Pérez D. (2019). Introducción a la limpieza y análisis de los datos. Editorial UOC.
- Megan Squire (2015). *Clean Data*. Packt Publishing Ltd.

- Jiawei Han, Micheline Kamber, Jian Pei (2012). *Data mining: concepts and techniques*. Morgan Kaufmann.
- Jason W. Osborne (2010). *Data Cleaning Basics: Best Practices in Dealing with Extreme Scores*. *Newborn and Infant Nursing Reviews*; 10 (1): pp. 1527-3369.
- Peter Dalgaard (2008). *Introductory statistics with R*. Springer Science & Business Media.
- Wes McKinney (2012). *Python for Data Analysis*. O'Reilley Media, Inc.
- Tutorial de Github <https://guides.github.com/activities/hello-world>.
- Eina per a la realització de gràfiques: <https://www.data-to-viz.com/>

Criteris de valoració

Tots els apartats són obligatoris. La ponderació dels exercicis és la següent:

Apartat	1	2	3	4	5	6	7	8
Punts	0,5	1	2	2	2	1	1	0,5

Es valorarà la idoneïtat de les respostes, que han de ser clares i completes. Les diferents etapes han d'estar ben justificades i acompanyades del codi corresponent. També es valorarà la síntesi i claredat, a través de l'ús de comentaris, del codi resultant, així com la qualitat de les dades finals analitzades.

Format i data de lliurament

Pel que fa al lliurament final, es demana:

- 1) **La memòria de la pràctica**, que haurà de ser un únic **document PDF**, amb les respostes a les preguntes, els noms dels components del grup i l'enllaç al repositori Git de la pràctica. **L'extensió d'aquest document no pot superar les 20 pàgines.**

A més, al final del document, haurà d'aparèixer la taula de contribucions següent al treball, la qual ha de signar cada integrant del grup amb les seves inicials. Les inicials representen la confirmació que l'integrant ha participat en aquest apartat. Tots els integrants han de participar a cada apartat, per la qual cosa, idealment, els apartats haurien d'estar signats per tots els integrants.

Contribucions	Signatura
Investigació prèvia	Integrant 1, Integrant 2

Redacció de les respostes	Integrant 1, Integrant 2
Desenvolupament del codi	Integrant 1, Integrant 2
Participació al vídeo	Integrant 1, Integrant 2

Aquest document es lliurarà a l'**Espai de Lliurament PR2 de l'aula Canvas**.

- 2) Un **repositori Git** amb les solucions de la pràctica. El dipòsit Git es crearà a Github (<https://github.com/>) i haurà de ser un **repositori privat**, per la qual cosa s'haurà de donar accés al professor mitjançant el nom d'usuari que indicarà al taulell d'Anuncis de l'aula o per correu electrònic. És responsabilitat de l'estudiant assegurar-se de que, en el moment del lliurament de la pràctica, **s'ha donat accés al professor als diferents elements privats que s'entreguen** (p. ej., repositori GitHub privat o arxius restringits de Google Drive).

El repositori no es podrà modificar passada la data de lliurament, i haurà de contenir:

- Un **README.md** amb els noms dels components del grup i una descripció dels fitxers que componen el repositori.
- Una carpeta amb el **codi generat** per analitzar les dades
- El **fitxer CSV amb les dades originals**.
- El **fitxer CSV amb les dades finals analitzades**.

- 3) Un **breu vídeo** amb la participació dels dos components del grup, on es farà una presentació del projecte, destacant els punts més rellevants. El vídeo s'haurà de compartir mitjançant un enllaç del Google Drive de la UOC o incloure'l al repositori Git. **La durada d'aquest vídeo no ha de superar els 10 minuts**. L'enllaç del mateix s'ha d'indicar a l'apartat 8 del document PDF.

És responsabilitat de l'estudiant revisar que el fitxer lliurat és el correcte. Un fitxer buit o no pertinent es considerarà com a no lliurat. Així mateix, perquè un lliurament es consideri com realitzat, s'ha de completar almenys el 25% de l'activitat.

Aquest document de lliurament final de la Pràctica 2 s'ha de lliurar a l'Espai de Lliurament PR1 de l'aula Canvas abans de les **23.59 h CET** del dia **28 de maig del 2026**. No s'acceptaran lliuraments fora de termini.

- No podrà modificar-se cap element de la pràctica passada la data de lliurament** (repositori, arxius de Google Drive, etc.).
- Pel que fa a l'ús de programari, llibreries o repositoris de tercers, s'hauran de complir les seves respectives llicències i condicions d'ús.

- La còpia o plagi en la realització de la pràctica comportarà la qualificació de suspens (D). El treball lliurat ha de ser original, citant adequadament les fonts bibliogràfiques utilitzades. Per a més informació i recursos podeu consultar:
 - **Integritat acadèmica i plagi:**
<https://campus.uoc.edu/estudiant/microsites/plagi/ca/index.html>
 - **Com citar correctament i evitar el plagi (Biblioteca UOC):**
<https://biblioteca.uoc.edu/ca/plana/Com-citar/>

Aquesta activitat és obligatòria. No entregar-la en la data i forma indicades implica el suspens automàtic de l'assignatura.

Si es considera oportú, el professor sol·licitarà als integrants del grup una entrevista remota (de manera conjunta o individual) mitjançant Google Meet, en referència a la pràctica realitzada, en un dia i hora acordats.

Propietat intel·lectual

Al presentar una pràctica o PAC que faci ús de recursos aliens, s'ha de presentar juntament amb ella un document en què es detallin tots ells, especificant el nom de cada recurs, el seu autor, el lloc on es va obtenir i el seu estatus legal: si l'obra està protegida pel copyright o s'acull a alguna altra llicència d'ús (Creative Commons, llicència GNU, GPL etc.). L'estudiant haurà d'assegurar que la llicència que sigui no impedeix específicament seu ús en el marc de la pràctica o PAC. En cas de no trobar la informació corresponent haurà d'assumir que l'obra està protegida pel copyright.